

Aprendizagem Computacional I

K-NEAREST NEIGHBORS ALGORITHM

ENRICO PACHECO SANCHEZ –

UP202400818

ENZO NASCENTES GRIGÓRIO –

UP202404041

MATHEUS GONÇALVES GUERRA –

UP202205324




SUMÁRIO

Objetivos

Principal objetivo analisar a vulnerabilidade do algoritmo KNN diante ruídos e outliers (grupo 1), e por fim propor um mecanismo de possível otimização que evite falhar ao encontrar tais anomalias, aumentando então sua robustez.


Abordagem

Na fase 1 estabelecemos um baseline com KNN em 50 datasets. Na fase 2, integramos algoritmos não supervisionados na tentativa de aplicar estratégias para evitar problemas e complicações com possíveis outliers e anomalias, sendo eles, o Isolation forest e o LOF (Local Outlier Factor) com peso, respectivamente para aplicar Hard Filtering e Soft weighting, alternativamente tentamos usar Adaptive LOF.




Resultados

Para a nossa surpresa, a manipulação desses outliers ao invés de otimizar acabou por degradar o modelo previamente implementado. E por meio da validação estatística (Wilcoxon) provamos que o KNN puro, principalmente para 'k' maiores, acaba por ser mais robusto que os filtros aplicados.



K-NEAREST NEIGHBORS ALGORITHM



O algoritmo KNN classifica novos dados analisando matematicamente a sua vizinhança. Medindo a distância exata até os 'K' pontos mais próximos, podendo então atribuir ao novo dado a categoria mais frequente entre eles. Possibilitando por meio dessa “votação” mapear fronteiras de decisão complexas e irregulares mais facilmente.

K-NEAREST NEIGHBORS ALGORITHM

Possíveis vantagens



- Simples e Direto: Se trata de um algoritmo intuitivo e de fácil compreensão.
- Aprendizado Instantâneo: Não demanda de tempo de treino longo, tendo o modelo pronto ao carregar os dados.
- Flexibilidade: Se adaptar muito bem a novos dados adicionados ao sistema, sem ter a necessidade de recomeçar ao adiciona-los.

Possíveis desvantagens

- Lento em Grandes Bases: Por precisar calcular a distância entre todos os pontos, sofre quando a base de dados é grande.
- Consumo de Memória: Também por precisar armazenar todos os dados na memória para funcionar acaba exigindo muito hardware.
- Sensível a Ruídos: Ao se deparar com outliers, o KNN pode se confundir na classificação.


VULNERABILIDADE DO KNN PERANTE OUTLIERS

- Dependence cegamente da distância: Por conta de o KNN se basear puramente na proximidade espacial possível outliers distorcem as fronteiras de decisão, levando a classificação para categorias erradas.
- Problemas com $K=1$: Ao ter um único vizinho o impacto pode ser ainda maior. Pois sem qualquer filtro um único ponto anormal dita o resultado final do modelo, causando imensas quedas na precisão.



Inércia do algoritmo

O KNN se trata de um algoritmo que assume que todos os pontos de treino são igualmente confiáveis. Logo, em ambientes ruidosos sofre por não possuir um mecanismo nativo que o possibilite de combater esses ruídos.



Distorção de vizinhança

Podendo sofrer de distorção, como por exemplo, ao possuir apenas um outlier posicionado próximo à fronteira de decisão, podendo corromper toda esta região, puxando-a pra si, principalmente em valores baixos de 'k', onde não há volume o suficiente para contornar isto.

PROBLEMAS E POSSÍVEIS SOLUÇÕES

HIPÓTESE DE SOLUÇÃO


Hipotetizamos que, poderíamos integrar algoritmos de detecção de anomalias antes de realizar a consulta, criando assim então um hipotético "KNN aprimorado", capaz de ignorar ou reduzir a influência negativa que vizinhos poucos confiáveis traziam à análise de dados, contornando assim tanto a inércia que o algoritmo sofre, quanto a possível distorção em outliers em posições infortunadas.

SOLUÇÕES PROPOSTAS


LOCAL OUTLIER FACTOR

ADAPTATIVE LOF


ISOLATION FOREST



LOCAL OUTLIER FACTOR



ISOLATION FOREST





LOCAL OUTLIER FACTOR

CONCEITO

Se trata de um algoritmo baseado na densidade local que identifica as anomalias ao comparar a densidade de um ponto com a de seus vizinhos.

FUNCIONAMENTO

Calcula o “Local outlier factor”. E se a densidade de um ponto for consideravelmente inferior à de seus vizinhos, ele recebe um peso elevado, indicando sua irregularidade em torno deles.




VANTAGENS

Ótimo para detectar anomalias locais em datasets com múltiplas densidades, ou seja, pontos que são irregulares em relação ao grupo onde estão localizados.

FUNCIONAMENTO

Funciona criando árvores de decisão aleatórias, onde a partir dessas os outliers são isolados em caminhos que são curtos, o mais próximo da raiz da árvore, enquanto os pontos normais precisam de mais divisões.



VANTAGENS

Muito eficiente em datasets de alta dimensão e muito volumosos, oferecendo uma visão global da anomalia sem ter o mesmo custo computacional ao calcular distâncias em LOF.

ISOLATION FOREST

CONCEITO

Diferentemente do LOF, este algoritmo se baseia no princípio de isolamento de pontos. Presumindo que as anomalias são poucas e distinguíveis facilitando então seu isolamento das outras.

ADAPTATIVE LOF (ALOF)

Ideia Central: Um modelo onde o valor de k não é fixo. O algoritmo ajusta o k dinamicamente para cada ponto, guiando-se pela densidade espacial calculada pelo LOF

Para regiões limpas: usamos k mínimo ($k=3$)
Para regiões com ruído: usamos k máximo ($k=11$)

Implementação da função
`AdaptiveKNNClassifier`

RESULTADO: Um K dependente de contexto local

SETUP EXPERIMENTAL

DEFINIÇÃO DAS METODOLOGIAS DE TESTES

DATASETS DE BENCHMARK

49 datasets reais de classificação binária e multiclasse extraídos da plataforma OpenML (1 dataset excluído devido a dados em falta).

AMOSTRAGEM DE INSTÂNCIAS

Limitação a um máximo de 500 exemplos por dataset ($\text{MAX_SAMPLES} = 500$) com semente aleatória fixa ($\text{seed}=42$) para garantir consistência e reprodutibilidade.

METODOLOGIA DE ESTIMAÇÃO

Validação Cruzada Estruturada de 10-Folds (divisões de treino/teste idênticas para todos os modelos).

HIPERPARÂMETROS

- Tamanho de Vizinhança: Valores de k em $\{1, 3, 5, 11\}$ (Fase 1) e k em $\{5, 7, 11\}$ (Fase 2).
- Métrica de Distância: Distância Euclidiana padrão aplicada sobre instâncias numéricas.

RESULTADOS FASE 1


VULNERABILIDADE A OUTLIERS

Hipótese de ruído local

Vizinhos muito pequenos (sobretudo $k=1$) são altamente suscetíveis a outliers e ruídos de rotulagem por carecerem de consenso estatístico.

Teste global de Friedman

Indicou uma diferença global altamente significativa entre as vizinhanças (p-value próximo de 0.0, rejeitando fortemente a hipótese nula).



Ranqueamento médio de desempenho

- $k = 11 \rightarrow$ Rank médio: 1.48 (melhor baseline)
- $k = 5 \rightarrow$ Rank médio: 2.06
- $k = 3 \rightarrow$ Rank médio: 2.87
- $k = 1 \rightarrow$ Rank Médio: 3.59 (Pior modelo de forma estatisticamente significativa)

RESULTADOS FASE 2

VOTAÇÃO PONDERADA

A Proposta (Soft Weighting)

Mitigar a influência de anomalias calculando pesos $w_i \in [0, 1]$ via MinMaxScaler aplicados sobre scores de Isolation Forest, LOF e ALOF no conjunto de treino.

Degradação de Desempenho

▼ Isolation Forest

Perda média de -0.73% (k=5) e -0.90% (k=11)

▼ Local Outlier Factor (LOF)

Perda média de -0.43% (k=5) e -0.36% (k=11)

▼ Adaptative LOF (ALOF)

Perda média de -0.03% (k=3) e -0.82% (k=11)

Acurácia Média Global


Método	k = 3	k = 5	k = 11
kNN Base		78.93%	79.03%
iForest-W		78.20% ▼	78.13% ▼
LOF-W		78.50% ▼	78.67% ▼
ALOF	78.90% ▼		78.21% ▼

Conclusão

A ponderação suave (soft weighting) não melhorou o kNN base. Ambas as variantes apresentaram queda de desempenho, sugerindo que a atenuação uniforme de outliers prejudica a discriminação local do classificador.

ETAPA 2

VALIDAÇÃO DE WILCOXON



Pergunta Estatística

As abordagens ponderadas com normalização MinMaxScaler são estatisticamente superiores ao baseline tradicional?

p-values Pareados (Unicaudal)

Condição	p-value iForest	p-value LOF	ALOF
k = 5	0.9829	0.9953	–
k = 11	0.9993	0.9965	0.9938
k = 3	–	–	0.5875

Veredito Estatístico

 **Hipótese de superioridade REJEITADA**

Com p-values extremamente próximos de 1.0, a hipótese de superioridade é rejeitada de forma esmagadora.

O kNN puro (sem pesos) é estatisticamente superior e preferível face a ambos os esquemas com pesos relativos.

Método: Teste não-paramétrico pareado de Wilcoxon (Ponderado vs Base), unicaudal, avaliando se a variante ponderada supera o baseline.

DISCUSSÃO

O ERRO LÓGICO E MATEMÁTICO DA NORMALIZAÇÃO RELATIVA



1. O Mecanismo da Falha

A escala linear do MinMaxScaler força obrigatoriamente a pior densidade do treino a receber peso integral 0.0 e a melhor peso 1.0.

2. A Geração de Ruído Artificial

Em conjuntos de treino limpos e livres de anomalias, alguns exemplos perfeitamente válidos e saudáveis localizados nas áreas periféricas da distribuição de dados são silenciados (peso 0.0) ou severamente atenuados de forma artificial.

3. Enfraquecimento da Fronteira Local

Ao depreciar border-points fundamentais de transição de classe que foram falsamente marcados como outliers de baixa densidade relativa, destrói-se a capacidade preditiva do modelo nas fronteiras finas.

O ALOF aumenta o raio para se defender do "ruído", causando alisamento (oversmoothing) justamente onde o corte deveria ser fino

Contraste Visual

✓ kNN Base

Todos os pontos de treino contribuem igualmente. Border-points preservados. Fronteiras intactas.

VS

✗ MinMaxScaler Weighting

Pontos periféricos saudáveis silenciados. Border-points eliminados. Fronteiras destruídas.

Conclusão: A normalização relativa é fundamentalmente incompatível com classificadores baseados em vizinhança local quando o treino não contém anomalias reais.

CONCLUSÃO

LIÇÕES CIENTÍFICAS DO ESTUDO REALIZADO

Robustez Passiva Superior:

O mecanismo mais fiável para proteger o kNN contra ruído e outliers é a votação majoritária natural, mantendo vizinhanças maiores ($k \geq 5$).

Falha nas abordagens geométricas

Tentar punir outliers através de "pesos zero" provou ser mecanicamente ineficiente. Outliers com peso zero ainda ocupam as preciosas "vagas" da vizinhança top-k, reduzindo drasticamente o número de vizinhos úteis para a votação.

PARA TRABALHOS FUTUROS:

Apesar dos esforços mecânicos, algoritmos puros de densidade espacial (Isolation Forest e LOF) esbarram na Erosão de Fronteira. Eles são incapazes de diferenciar ruído genuíno de esparsidade natural de fronteira, confirmando que o tratamento de anomalias em classificação exige métodos que consultem o rótulo da classe (filtros supervisionados).